PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Projeto Análise e Comportamento dos Repasses da Arrecadação Federal a Terceiros

Curso e turma Sistemas de Informação • 6º Período

Professor ou professora Marina de Lara

Equipe Arthur de Oliveira Carvalho, Caio Eduardo Lamoglia, João Victor Saboya Ribeiro de Carvalho, Matheus De Bortoli Silva

Repositório https://github.com/Jvictoroak/Data-Ingestion-and-Data-Quality

Entrega Curitiba ? 21/10/2026

Este documento acompanha a implementação no repositório. Registre o caminho dos arquivos, notebooks ou células que comprovam cada etapa. O resultado do RA1 será a base para os próximos RAs.s

RA1 / 01

Problema e perguntas analíticas

Defina o contexto do projeto e as perguntas que orientarão a seleção e a preparação dos dados.

Contexto e problema

A arrecadação federal movimenta trilhões de reais anualmente. Parte significativa desses recursos é direcionada a outras entidades e fundos públicos e privados (conhecidos comumente como "terceiros", arrecadados via DARF e GPS). Compreender o destino, a volumetria e a dinâmica desses repasses é fundamental para a transparência fiscal e para a análise do financiamento de políticas públicas, educação, seguridade e serviços sociais autônomos no Brasil. O problema afeta gestores públicos, pesquisadores e a sociedade interessada no fluxo orçamentário e financeiro do Estado.

Objetivo e recorte

O objetivo deste estudo é realizar a ingestão, avaliação de qualidade, limpeza e preparação dos dados de repasses da arrecadação federal entre janeiro de 2015 e agosto de 2026. A unidade de análise compreende os repasses mensais consolidados por entidade beneficiária cadastrada.

Perguntas analíticas

ID	Pergunta a investigar	Dados necessários
P1	Como o volume total repassado varia entre as diferentes entidades ao longo do tempo?	Mês / Ano de Referência, Entidade, Total Repassado
P2	Quais instituições concentram os maiores volumes financeiros dentro da categoria de repasses a terceiros?	Entidade, UC/CNPJ, Total Repassado
P3	Existem padrões sazonais ou anomalias recorrentes nos repasses em determinados meses do ano (ex: janeiro)?	Mês / Ano de Referência, Total Repassado, Entidade

Viabilidade inicial

Os dados públicos disponíveis cobrem a série histórica detalhada mensalmente de 2015 a 2026, contendo identificadores unificados das entidades e valores monetários que permitem responder com precisão às perguntas propostas, havendo apenas desafios pontuais de padronização textual e formatação numérica que foram tratados na etapa de limpeza.

RA1 / 02

Fontes de dados e ingestão

Documente a origem dos dados e como eles são carregados no ambiente do projeto. Duplique a ficha para cada fonte.

Ficha da fonte

Identificação F1 • Repasses da Arrecadação Federal

Origem e acesso Governo Federal (Portal Dados.gov.br / Cópia em ambiente de projeto) • https://dados.gov.br/dados/conjuntos-dados/repasses-da-arrecadacao-federal • Acesso em: set/2026

Formato e volume CSV (separado por ponto e vírgula) • Aproximadamente 2.397 registros brutos • 4 atributos principais

Cobertura Janeiro de 2015 a Agosto de 2026 • Âmbito nacional

Condições de uso Dados abertos governamentais sob licença de uso livre.

Relação com o problema

Esta fonte fornece diretamente os registros mensais de repasses por entidade, sustentando as análises de volume temporal, concentração de recursos e sazonalidade (P1, P2 e P3).

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Leitura do CSV diretamente da URL compartilhada no Google Drive.	Notebook enviado (célula de ingestão e leitura do CSV)
2	Leitura com pd.read_csv(url, sep=';') e conferência inicial com df.head().	Notebook enviado (célula de leitura do CSV)
3	Extração do ID por expressão regular e montagem da URL de download.	Notebook enviado (célula de construção da URL)

Resultado da ingestão

O CSV foi carregado diretamente do Google Drive com 2.397 linhas e 4 colunas, conforme a inspeção inicial da base.

RA1 / 03

Compreensão e qualidade

Descreva o que cada registro representa e apresente evidências das verificações de qualidade relevantes para os dados.

Unidade de observação Uma linha representa o valor financeiro total repassado a uma determinada entidade em um mês/ano de referência específico.

Identificação dos registros Identificação dos registros Chave composta por Mês / Ano de Referência + Entidade (um repasse único por mês para cada entidade).

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
Mês / Ano de Referência	Período competência do repasse	Texto (lido como str)	Formato "mmm/aa" (ex: jan/15)
Entidade	Nome abreviado da instituição beneficiária	Texto (str)	Categoria textual (ex: FNDE, SESC, SENAI)
UC/CNPJ	Identificador fiscal ou código de unidade contábil	Texto (str)	Padrão CNPJ (00.000.000/0000-00) ou código numérico
Total Repassado	Valor monetário repassado no período	Texto (str)	Formato monetário brasileiro (ponto milhar, vírgula decimal)

Diagnóstico de qualidade

ID	Verificação e regra	Resultado observado	Evidência
Q1	Valores ausentes / nulos	17 linhas totalmente vazias no final do arquivo; 0 nulos parciais	Notebook (Célula de Diagnóstico Q1)
Q2	Registros duplicados (linhas idênticas)	16 linhas idênticas correspondendo às linhas totalmente vazias	Notebook (Célula de Diagnóstico Q2/Q3)
Q3	Duplicidade por chave de negócio (Mês + Entidade)	0 duplicidades reais após padronização de nomes de entidades	Notebook (Célula de Diagnóstico Q3)
Q4	Tipos de dados incorretos	Data e valor lidos como string (object), exigindo conversão explícita	Notebook (Célula de Diagnóstico Q4)
Q5	Formatos inconsistentes em 'Total Repassado'	Dois padrões: até set/25 com separador de milhar; a partir de out/25 sem separador de milhar	Notebook (Célula de Diagnóstico Q5)
Q6	Categorias inconsistentes na coluna 'Entidade'	Presença de espaços extras nas pontas e duplicidade conceitual ("APEX" e "APEX-BR") com mesmo CNPJ e períodos disjuntos	Notebook (Célula de Diagnóstico Q6)

ID	Verificação e regra	Resultado observado	Evidência
Q7	Formato do identificador (UC/CNPJ)	Convivência de CPFs/CNPJs formatados e códigos numéricos de unidades contábeis	Notebook (Célula de Diagnóstico Q7)
Q8	Valores inválidos ou impossíveis (negativos e zeros)	1 valor negativo isolado (estorno/ajuste na ANAC em jan/25) e 134 valores zerados (concentrados na EMBRATUR)	Notebook (Célula de Diagnóstico Q8)
Q9	Cobertura temporal por entidade	17 entidades avaliadas ao longo da série histórica	Notebook (Célula de Diagnóstico Q9)
Q10	Possíveis outliers (método IQR por entidade)	52 valores apontados como outliers, fortemente concentrados no mês de janeiro (sazonalidade de repasses)	Notebook (Célula de Diagnóstico Q10)

Impacto dos problemas identificados

A ausência de conversão de tipos impedia cálculos numéricos e ordenação cronológica. Inconsistências de formatação monetária e variações textuais de entidades poderiam gerar duplicações artificiais de categorias ou perdas de agregação caso não fossem rigorosamente tratadas.

RA1 / 04

Limpeza e preparação

Relacione cada intervenção ao diagnóstico. Justifique tanto os tratamentos realizados quanto as decisões de manter os dados.

Registro das decisões

Decisão e diagnóstico D1 a D2 • relacionado a Q1 e Q2

Problema e abrangência

17 linhas totalmente vazias no final do arquivo bruto.

Tratamento e justificativa

Remoção das linhas vazias (dropna(how="all")), pois não continham dados analíticos e representavam artefatos de exportação do sistema de origem.

Implementação Notebook (Célula de Limpeza D1 e D2)

Validação após o tratamento

Verificação de que o somatório de nulos remanescentess é igual a zero (assert df.isna().sum().sum() == 0).

Decisão e diagnóstico D3 • relacionado a Q6

Problema e abrangência

Variações textuais e nomenclatura bipartida da entidade APEX.

Tratamento e justificativa

Aplicação de str.strip() em todas as colunas textuais e unificação de "APEX" para "APEX-BR" (comprovado por compartilhamento do mesmo CNPJ e ausência de sobreposição temporal).

Implementação Notebook (Célula D3)

Validação após o tratamento

Contagem distinta de entidades passa a refletir exatamente 17 instituições padronizadas

Decisão e diagnóstico D4 e D5 • relacionado a Q4 e Q5

Problema e abrangência

Colunas de data (Mês / Ano de Referência) e valor (Total Repassado) em formato texto.

Tratamento e justificativa

Conversão da data para o formato datetime (primeiro dia de cada mês, assumindo o século 21 para anos de 15 a 26) e conversão do valor monetário com tratamento de pontos de milhar e substituição de vírgula decimal por ponto.

Implementação Notebook (Função converte_valor e células D4 e D5)

Validação após o tratamento

Tipos convertidos com sucesso para datetime64[ns] e float64 sem geração de novos nulos.

Decisão e diagnóstico D6, D7 e D8 • relacionado a Q8 e Q10

Problema e abrangência

Presença de 1 valor negativo, 134 zeros estruturais e valores considerados outliers pelo IQR

Tratamento e justificativa

Mantidos. O valor negativo refere-se a um ajuste contábil/estorno oficial legítimo; os zeros na EMBRATUR representam ausência de repasses no período (zero estrutural); os outliers concentram-se em janeiro devido à sazonalidade fiscal legítima de repasses anuais. Excluí-los distorceria a realidade da série temporal.

Implementação Notebook (Células D6, D7 e D8)

Validação após o tratamento

Confirmação de manutenção controlada dos registros e sinalização documentada para tratamento em agregações futuras no RA2

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência

Decisão	Ação executada	Impacto nos dados	Evidência
D1-D2	Remoção de linhas totalmente vazias	17 registros eliminados (fim do arquivo)	Notebook (Célula D1/D2)
D3	Padronização de strings e unificação de "APEX" em "APEX-BR"	Padronização de nomenclaturas de entidades	Notebook (Célula D3)
D4	Conversão do campo textual de data para tipo datetime	Coluna de data convertida para datetime64[ns]	Notebook (Célula D4)
D5	Conversão de valores monetários para tipo numérico float	Coluna monetária convertida para float64	Notebook (Célula D5)
D6-D8	Manutenção justificada de negativos, zeros e outliers	Preservação da fidelidade dos dados originais sem exclusões arbitrárias	Notebook (Célula D6 a D8)

RA1 / 05

Conjunto de dados resultante

Identifique a saída do RA1 e demonstre sua consistência para uso nas próximas etapas.

Arquivo final: repasses_arrecadacao_federal_limpo.csv ? Pasta atual ? CSV (;)

CSV (separador ;)

Unidade de observação final Um registro representa o repasse financeiro mensal consolidado para uma entidade federal específica

Dicionário atualizado Consulte a seção de atributos (RA1 / 03)

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros	2.397	2.380	Redução de 17 registros correspondentes às linhas totalmente vazias do arquivo bruto
Atributos	4	4	Sem alteração na quantidade de colunas
Nulos / Células vazias	68	0	Tratamento completo das linhas vazias e conversão estrita

Verificações finais

Testes automatizados via assert confirmam: zero valores nulos, ausência de duplicatas na chave composta (Mês + Entidade), exatamente 17 entidades distintas com 140 registros mensais cada (totalizando 2.380 linhas válidas cobrindo de janeiro de 2015 a agosto de 2026), e tipagens rigorosamente ajustadas para datetime64 e float64. Evidências registradas nas células de validação final do notebook.

Limitações e pendências

O conjunto apresenta uma leve perda de precisão decimal (< R$ 1 por registro) nos dados a partir de outubro de 2025 devido ao truncamento nativo na fonte oficial governamental. Valores negativos e sazonais exigem tratamentos analíticos específicos em métricas de soma/média no RA2.

RA1 / 06

Organização e reprodutibilidade

Explique como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/Jvictoroak/Data-Ingestion-and-Data-Quality • Branch main

Ambiente: Python, pandas e re; acesso ao Google Drive.
Versões das dependências não fixadas no notebook.

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	CSV acessado diretamente por URL do Google Drive
Código de ingestão e preparação	RA1_Repasses_da_arrecadação_Federal (1).ipynb
Dados preparados	repasses_arrecadacao_federal_limpo.csv (pasta atual)
Documentação e dependências	Notebook e documentação do projeto

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Abrir o notebook em Jupyter ou Google Colab e instalar pandas.	Ambiente preparado com pandas e acesso à fonte no Google Drive.
2	Executar sequencialmente as células do notebook de ingestão e limpeza.	Leitura do CSV, diagnósticos, limpeza e preparação da base.
3	Verificar o sucesso das asserções de integridade ao final do notebook	Exibição de mensagens de sucesso confirmando dimensões, tipos e ausência de nulos
4	Localizar o CSV gerado na pasta de execução do notebook.	Arquivo limpo pronto para consumo nas etapas do RA2

Verificação da reprodução

Fluxo executado integralmente com sucesso, gerando o dataset limpo com exatas 2.380 linhas e 17 entidades validadas.

RA1 / 07

Referências e anexos

Reúna as fontes utilizadas e os materiais complementares que ajudam a verificar a entrega.

Referências

Referências BRASIL. Ministério da Fazenda / Governo Federal. **Conjunto de dados: Repasses da Arrecadação Federal**. Disponível em: https://dados.gov.br/dados/conjuntos-dados/repasses-da-arrecadacao-federal. Acesso em: set/2026.

Conferência da entrega

☒ Problema, recorte e perguntas analíticas estão definidos.

☒ Fontes e procedimentos de ingestão estão documentados.

☒ A qualidade foi avaliada com evidências verificáveis.

☒ As decisões de limpeza estão justificadas e validadas.

☒ O conjunto de dados preparado está identificado.

☒ O repositório contém instruções suficientes para reprodução.

☒ Os campos-modelo foram preenchidos e os exemplos revisados.